Group 12

ATLAS INSIGHT

Từ dữ liệu lịch sử đến phân khúc & dự đoán bằng AI

QUAN SÁT ML

1.704

91,26% VARIANCE

7 PCs

MÔ HÌNH BENCHMARK

4

STAGE 1

Tổng quan dự án

DỮ LIỆU ML

1.704

142 quốc gia

BẢNG ĐA NGUỒN

3.104

2 nguồn theo nhà cung cấp

BIỂU ĐỒ

16

EDA + ML diagnostics

HAI DATABASE

2

SQLite + ChromaDB

STAGE 1 – DATA FOUNDATION

Nguồn thực → concat / merge → SQLite + ChromaDB → Imputation + EDA

STAGE 2 – AI & DEMO

StandardScaler → PCA → K-Means → Regression / Classification → Gradio

Quy tắc: không nhân đôi cùng quốc gia - năm khi huấn luyện ML.

Hai nguồn dữ liệu - cùng khóa ISO3 + year

GAPMINDER / PLOTLY

1.704 quan sát - 142 quốc gia
1952–2007 - GDP/người, dân số, tuổi thọ
Nguồn huấn luyện mô hình chính

WORLD BANK / SP.DYN.LE00.IN

1.400 quan sát chuẩn hóa - 140 quốc gia
Chỉ tiêu: tuổi thọ lúc sinh
Đối chiếu chất lượng & tích hợp đa nguồn

Nguồn World Bank không cung cấp GDP và các chỉ số sim_* trong nhánh tích hợp.

Data lineage - các bước xử lý rõ nguồn

01

GAPMINDER
1.704

→

02

WORLD BANK
1.400

→

03

CONCAT
3.104

→

04

LEFT JOIN
SIM_*

→

05

CLEAN
0 MISSING

Stage 2 được giữ trên 1.704 quốc gia–năm duy nhất (không dùng trực tiếp 3.104 dòng).

Đối chiếu nguồn cho thấy sai khác đo lường

CẶP SO SÁNH HỢP LỆ

1.394

Theo ISO3 + year

MAE GIỮA HAI NGUỒN

1,795

Đơn vị: năm

CHÊNH LỆCH > 5 NĂM

113

Cần điều tra riêng

VÍ DỤ KHÁC BIỆT LỚN

Rwanda 1992: 20,798 năm - Bosnia 1992: 20,211 năm - Cambodia 1977: 19,925 năm

Không lấy trung bình hai nguồn hoặc suy luận nguồn sai nếu chưa kiểm tra phương pháp.

Missing Values - có nguồn, có chiến lược

THIẾU MÔ PHỎNG

690

Trước khi xử lý đa nguồn

TUỔI THỌ WB THIẾU

6

Bù từ Gapminder, có audit

SAU LÀM SẠCH

0

Missing remaining

NUMERICAL + TIME SERIES

Median theo châu lục - ffill/bfill trong từng quốc gia

CATEGORICAL + PROVENANCE

Unknown - giữ bản gốc & cột nguồn khi imputation

3.104 dòng theo nguồn; 1.704 country–year duy nhất; VALIDATION PASS.

Data validation trên máy nhóm

VALIDATION PASS - 3.104 rows / 0 missing / 0 conflicts

```
PS F:\Final Project AI\AI_Data_Analyst_AI_Full_Project\AI_Data_Analyst_Project> python -c "import pandas as pd; d=pd.read_csv('data/processed/multisource_cle
an.csv'); m=pd.read_csv('data/processed/master_clean.csv'); cols=['sim_health_index','sim_education_index','sim_trend_index','sim_policy_group']; conflicts=i
nt(d.groupby('record_id')[cols].nunique().gt(1).sum().sum()); dup=int(d.duplicated(['data_source','iso_alpha','year']).sum()); missing=int(d.isna().sum().sum
()); print('Total rows:',len(d)); print('Unique country-year:',d.record_id.nunique()); print('Total missing:',missing); print('Duplicate source-country-year:
',dup); print('Inconsistent simulated indicators:',conflicts); print('Life expectancy imputed:',int(d.life_expectancy_imputed.sum())); print('Original AI mas
ter rows:',len(m)); assert len(d)==3104 and d.record_id.nunique()==1704 and missing==0 and dup==0 and conflicts==0 and int(d.life_expectancy_imputed.sum())==
6 and len(m)==1704; print('VALIDATION PASS')"
Total rows: 3104
Unique country-year: 1704
Total missing: 0
Duplicate source-country-year: 0
Inconsistent simulated indicators: 0
Life expectancy imputed: 6
Original AI master rows: 1704
VALIDATION PASS
```

2 mô hình lưu trữ - SQL & vector

SQLITE

Dữ liệu có cấu trúc
master_sparse · master_clean
master_with_clusters
Round-trip đọc/ghi thành công

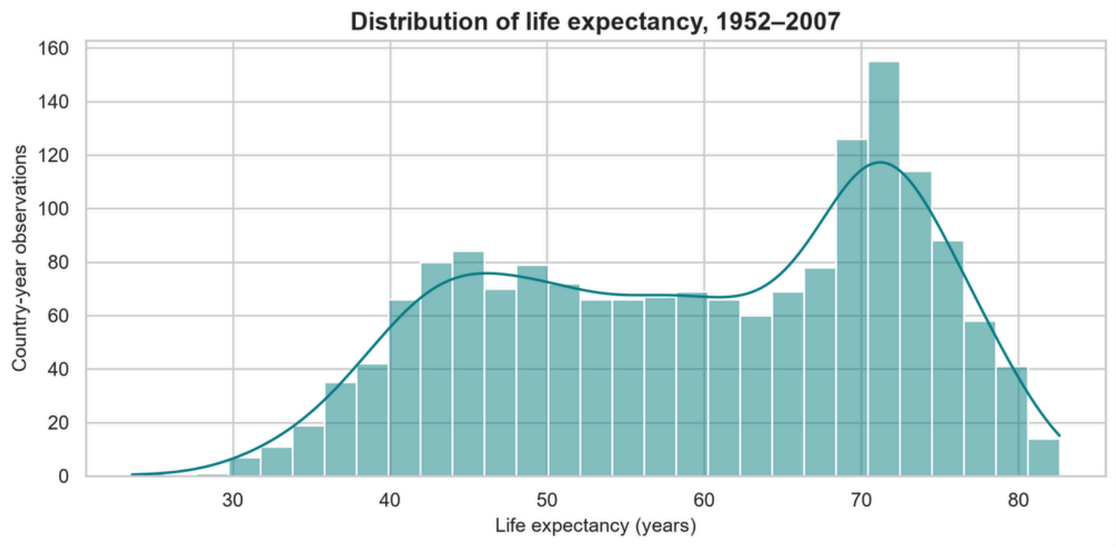
CHROMADB

PersistentClient /
country_year_embeddings
1.704 vectors · 7 dimensions
Truy vấn nearest-neighbor đã chạy

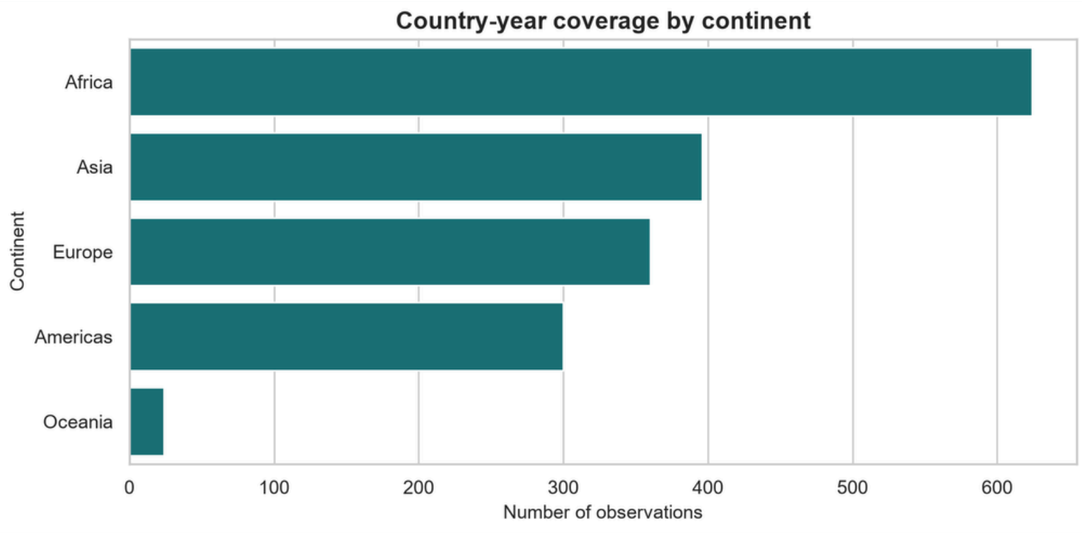
```
PS F:\Final Project AI\AI_Data_Analyst_AI_Full_Project\AI_Data_Analyst_Project> python src/04_chromadb_vector.py
{
  "ingested": true,
  "backend": "ChromaDB PersistentClient",
  "collection": "country_year_embeddings",
  "count": 1704,
  "dimensions": 7,
  "probe_record": "Afghanistan_1952",
  "nearest_ids": [
    "Afghanistan_1952",
    "Thailand_1952",
    "Nepal_1957"
  ]
}
```

EDA - dữ liệu số và nhãn phân loại

01 / AGE DISTRIBUTION + KDE



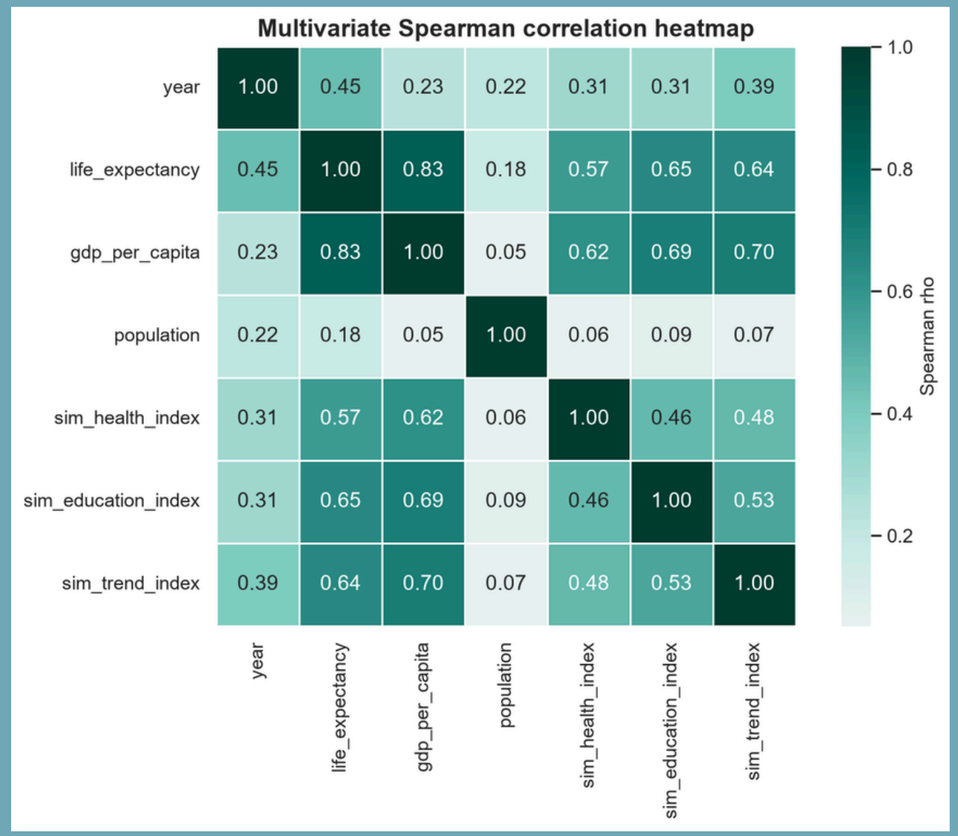
02 / OBSERVATION COUNTS



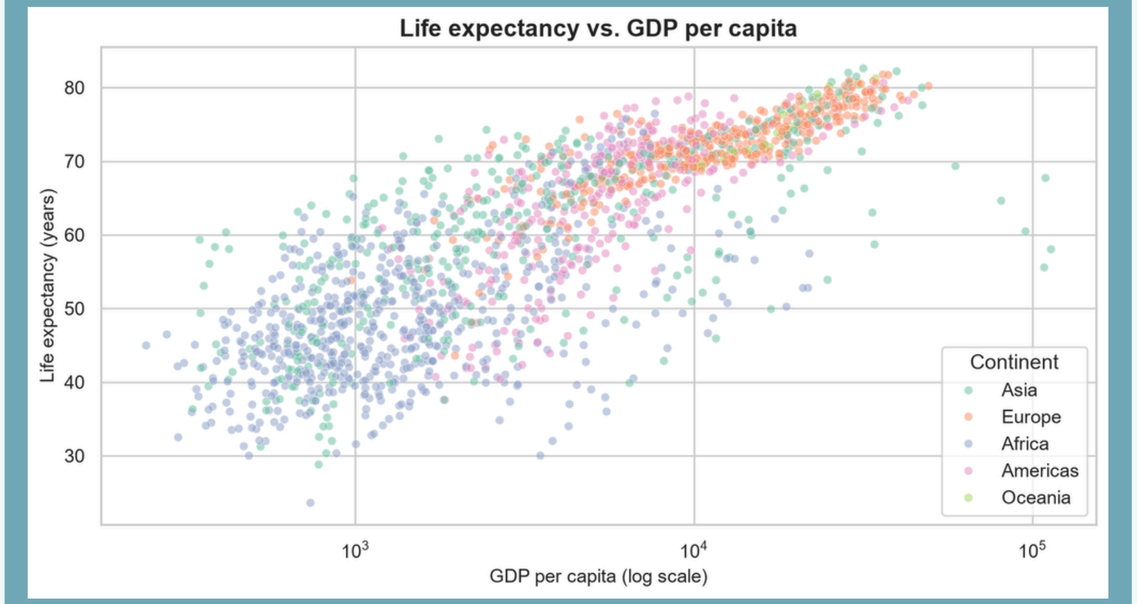
Insight: tuổi thọ trung bình lịch sử 59,47 năm; tỷ lệ quan sát giữa các vùng mất cân đối.

GDP và tuổi thọ - tương quan ≠ nhân quả

SPEARMAN HEATMAP



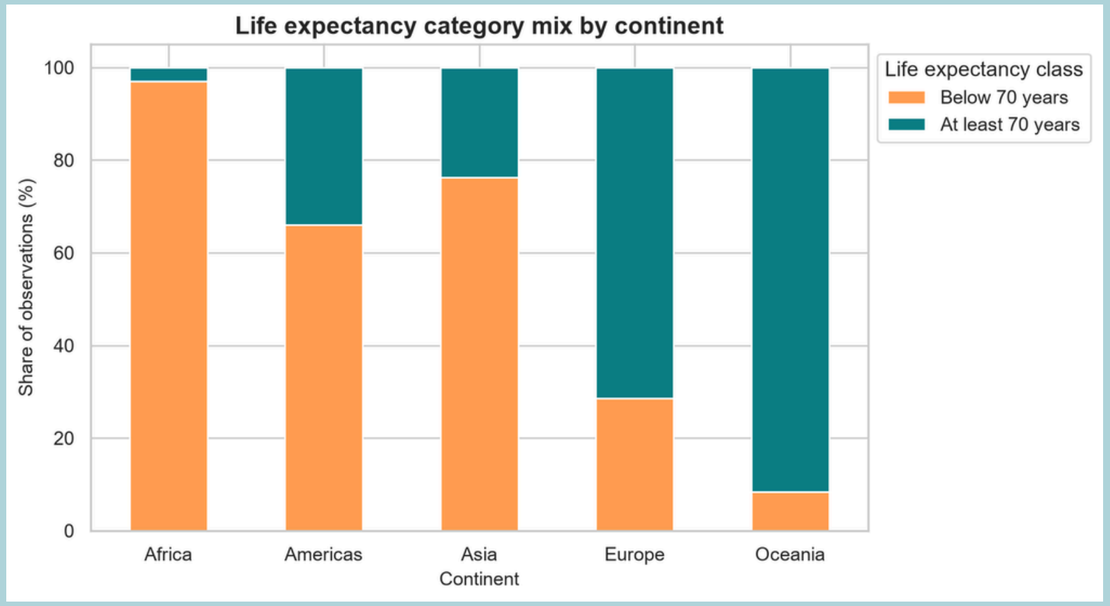
GDP/NGƯỜI VS TUỔI THỌ



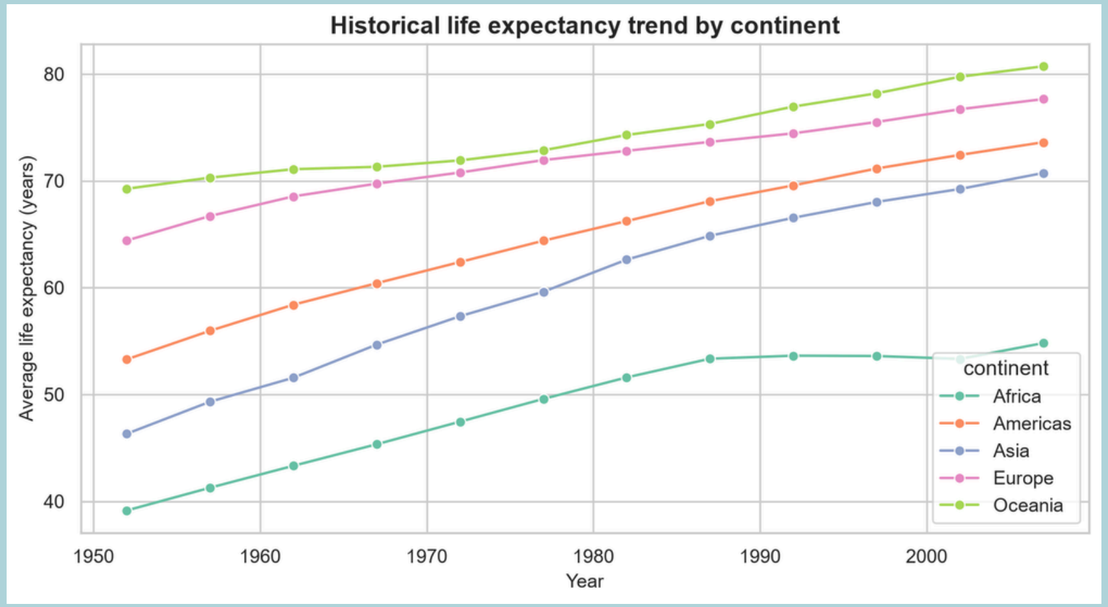
Spearman rho(GDP/người, tuổi thọ) = 0,8265; phải tách train/test theo quốc gia.

Insight theo nhóm & theo thời gian

CLASS MIX BY CONTINENT



LONGITUDINAL TREND

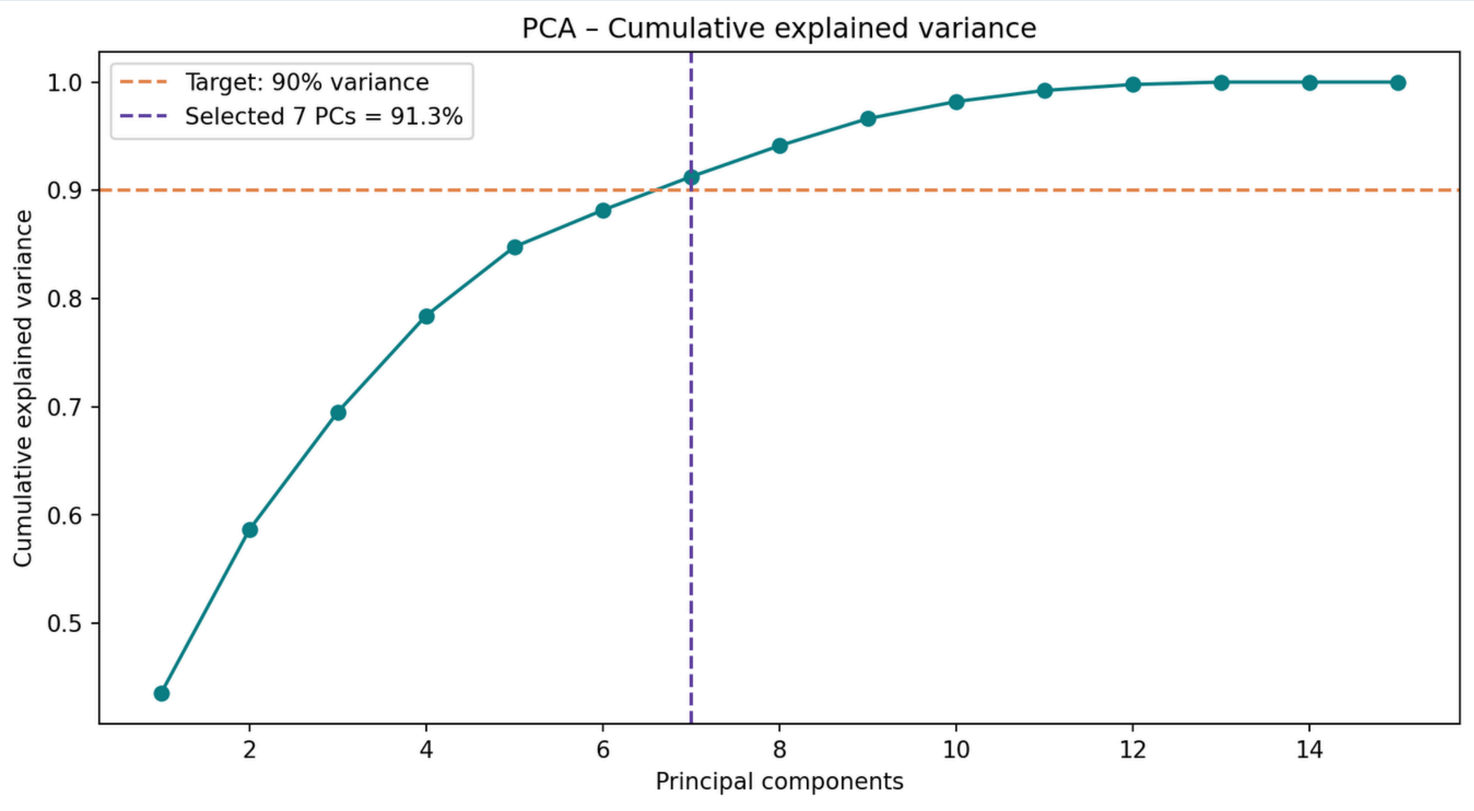


Cỡ mẫu vùng khác nhau, nhãn ≥70 mất cân đối, không diễn giải giai đoạn 1952–2007 như năm hiện tại.

STAGE 2

PCA - giữ 91,26% phương sai với 7 PCs

CUMULATIVE EXPLAINED VARIANCE



COMPONENTS

7 PCs

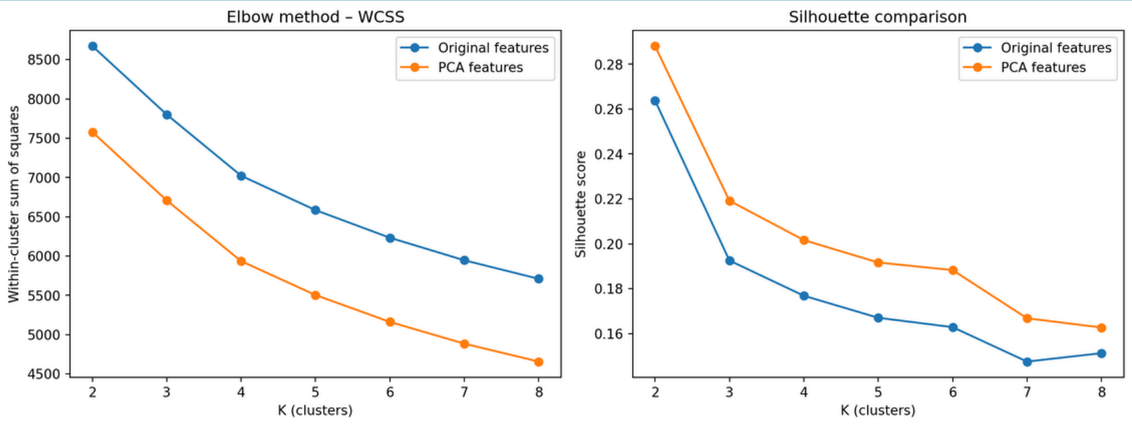
VARIANCE

91,26%

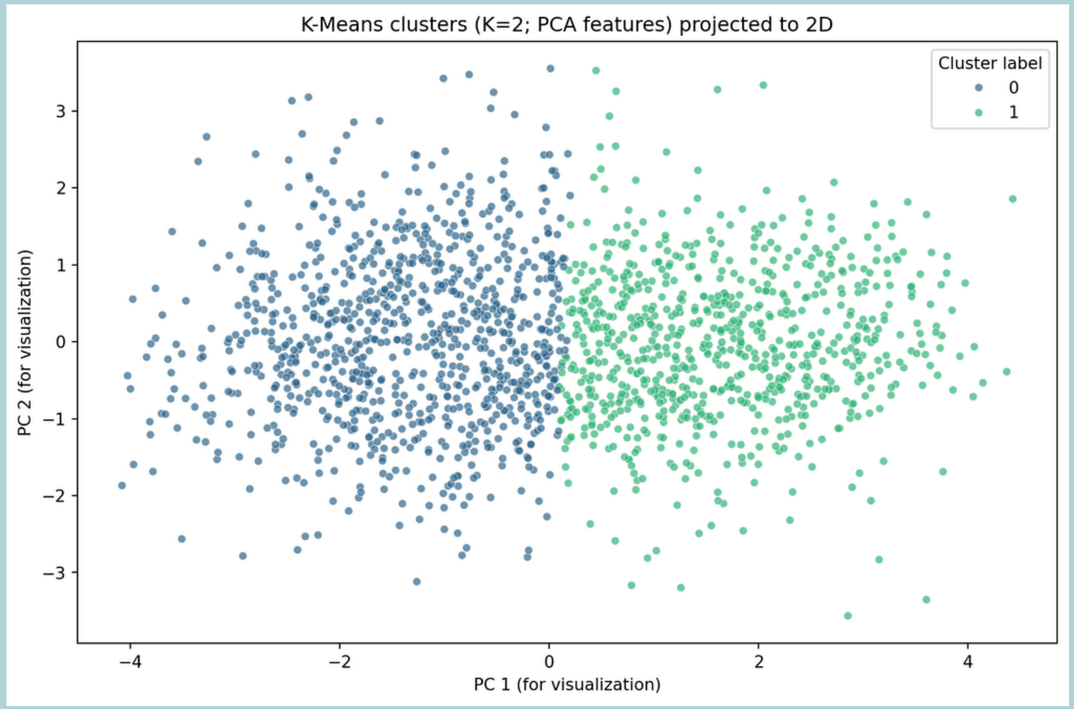
Chuẩn hóa trước PCA; chọn số PCs nhỏ nhất đạt ngưỡng 90%.

K-Means - PCA vượt đặc trưng gốc

ELBOW + SILHOUETTE



2 CLUSTERS PROJECTED TO 2D



K=2 - Silhouette PCA 0,288 > Original 0,264; chất lượng phân cụm còn ở mức vừa.

Cluster profiling - quan sát, không phán xét

CLUSTER 0 · 931 DÒNG

50,86

Tuổi thọ trung bình (năm)

CLUSTER 1 · 773 DÒNG

69,85

Tuổi thọ trung bình (năm)

GDP/NGƯỜI TRUNG VỊ

Cụm 0: $1.368 - Cụm 1: $9.867

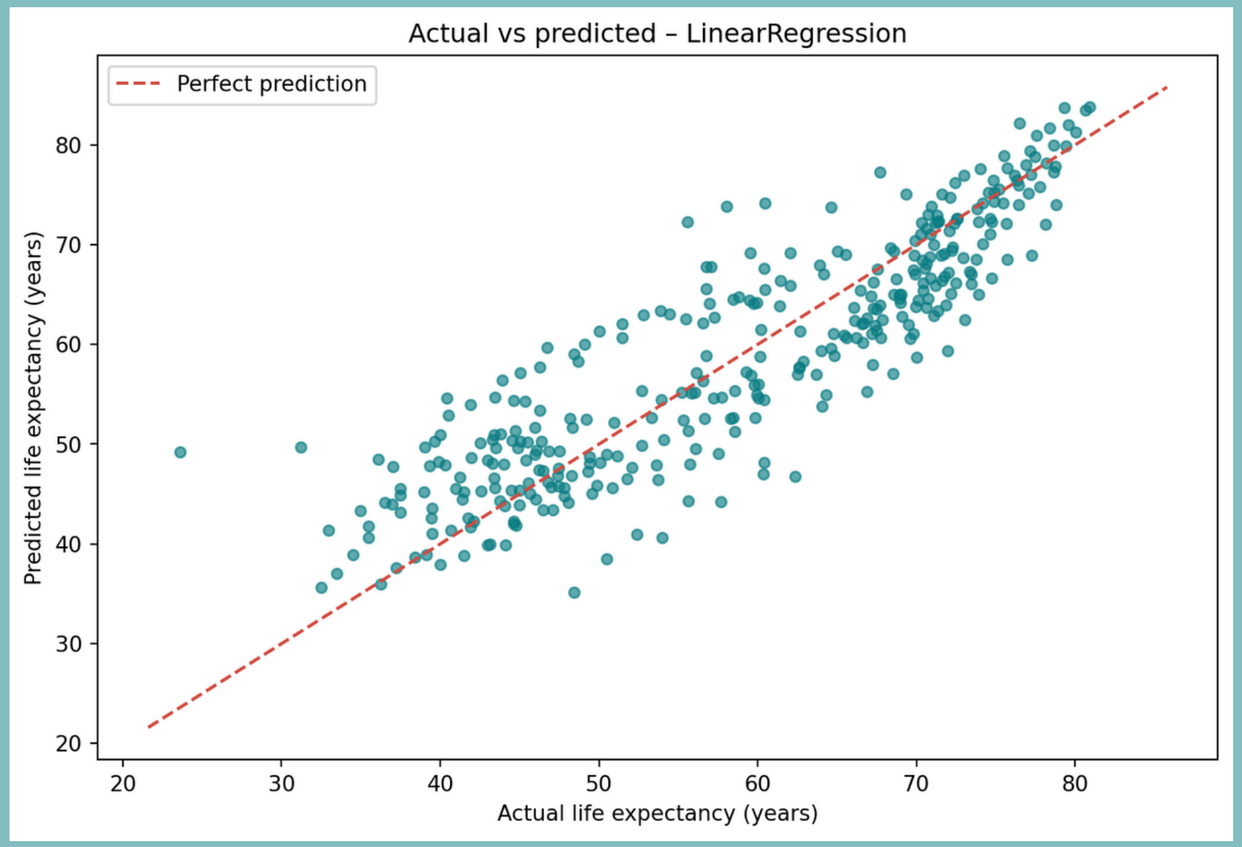
TỶ LỆ TUỔI THỌ ≥70

Cụm 0: 2,4% - Cụm 1: 61,1%

Không gọi các cụm là quốc gia “tốt/xấu” và không suy luận chính sách từ sim_health_index.

Regression benchmark - LinearRegression thắng

ACTUAL VS PREDICTED



LINEAR - RMSE

6,169

years

LINEAR - R^2

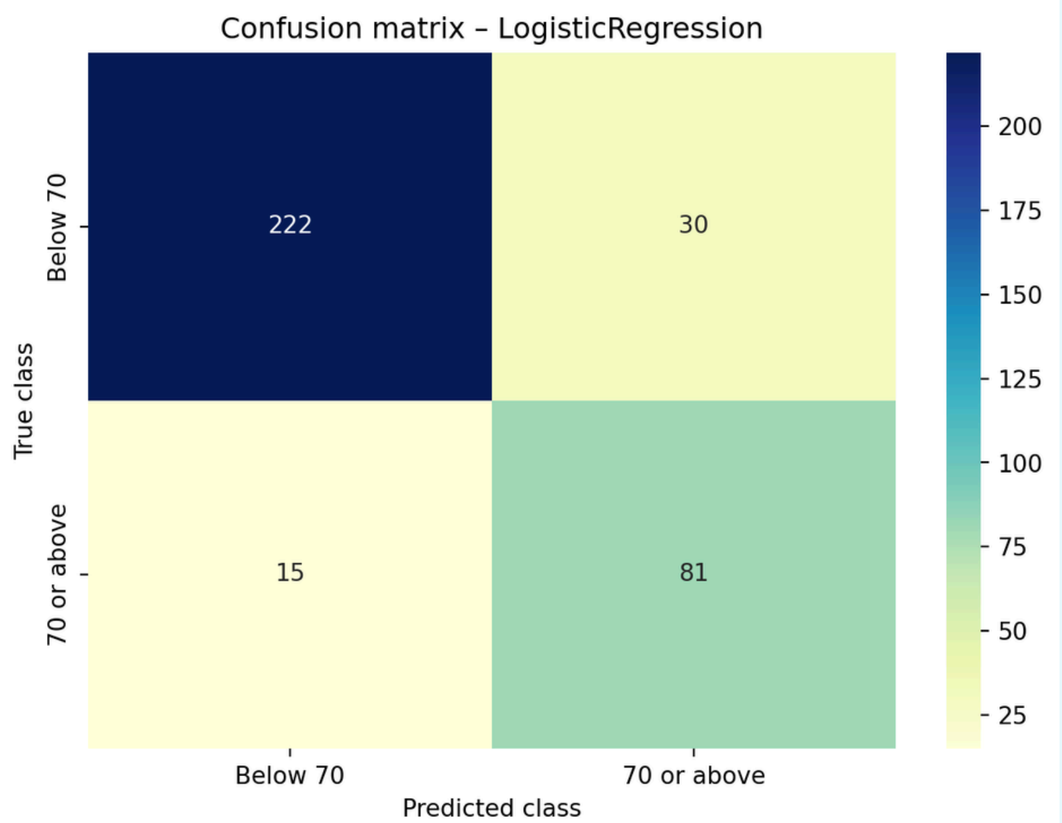
0,778

Tree RMSE = 6,730

Test được tách theo 29 quốc gia chưa thấy; RMSE 6,17 năm vẫn là sai số thực tế đáng kể.

Classification - LogisticRegression thắng

CONFUSION MATRIX



ACCURACY

87,07%

vs Tree 85,06%

F1 MACRO

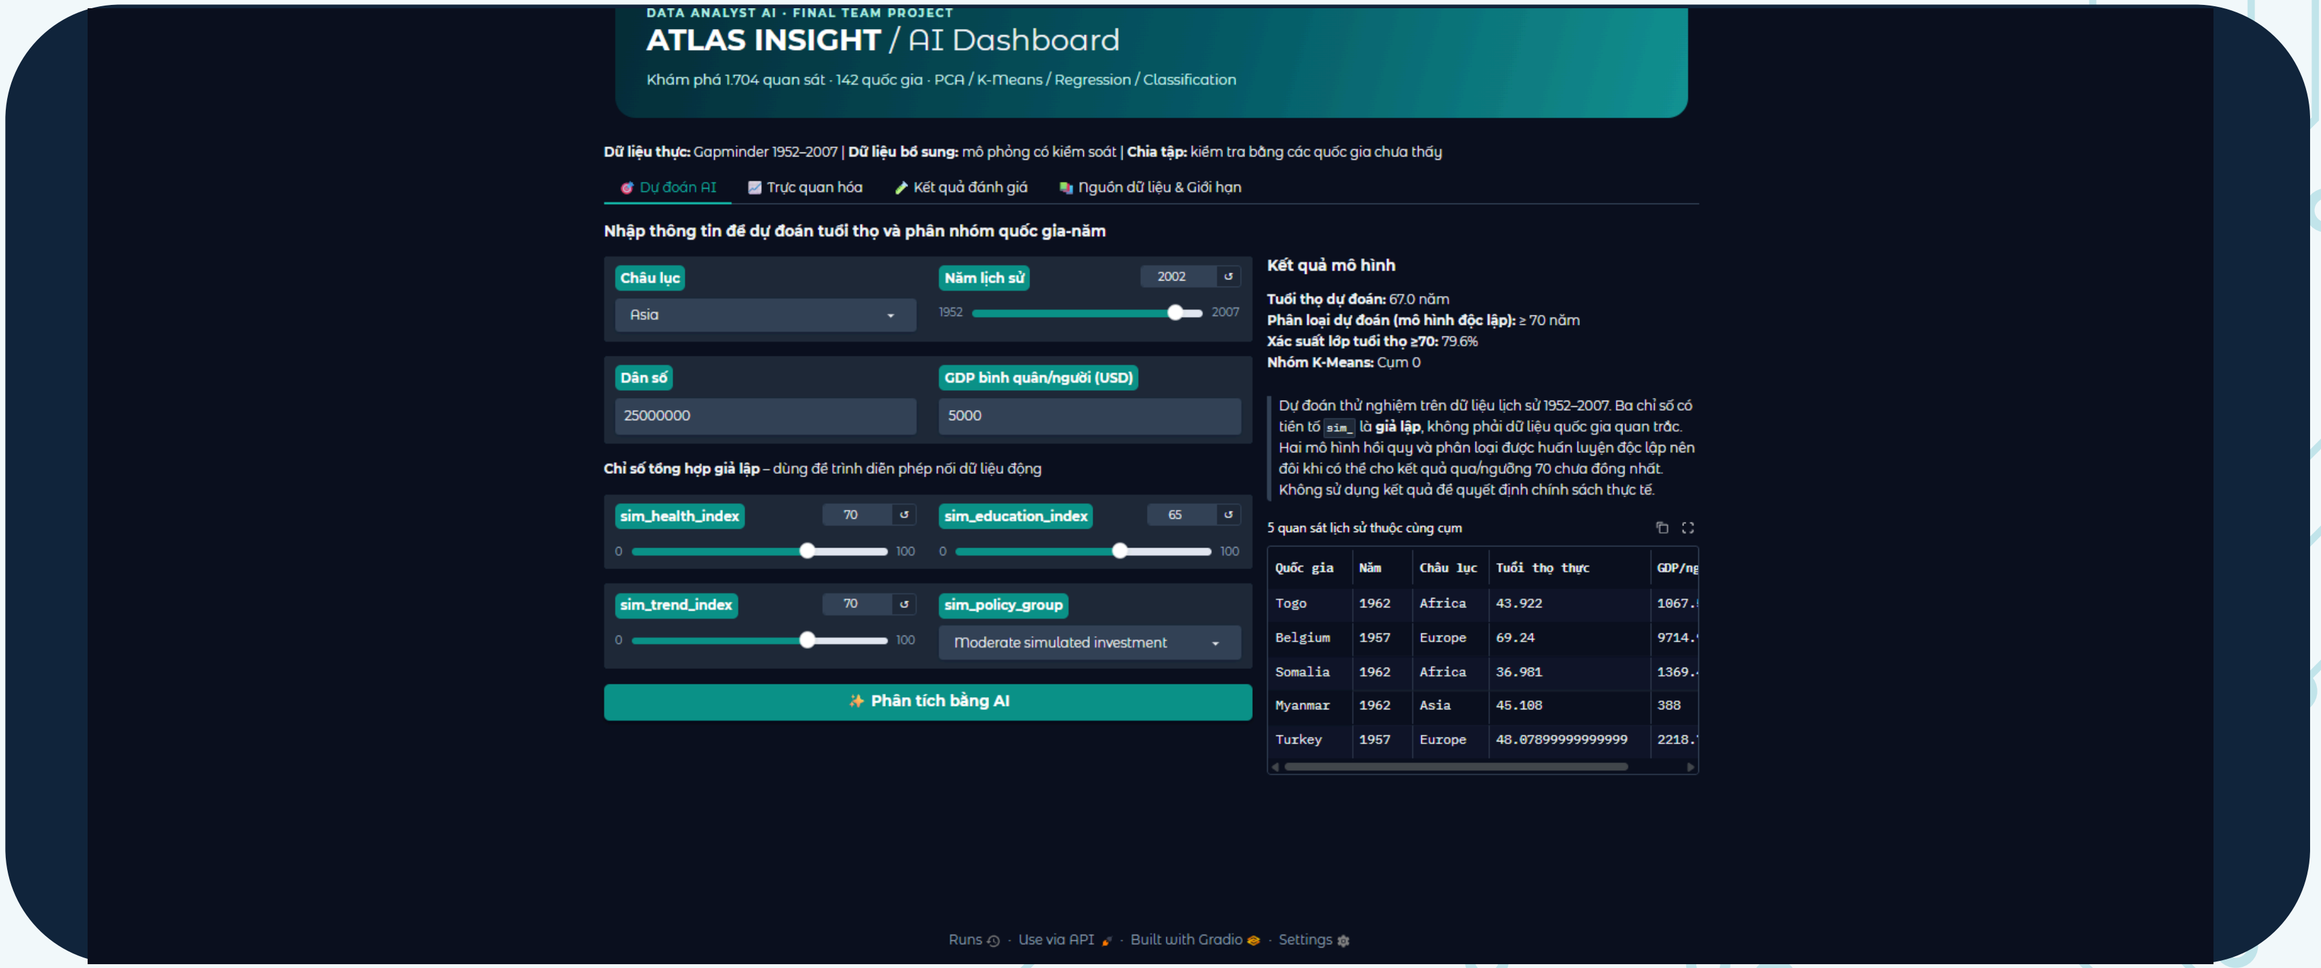
0,845

vs Tree 0,820

class_weight="balanced" khi nhãn mất cân bằng; F1 macro được dùng chọn mô hình.

Giao diện Gradio - nhập liệu và dự đoán

SCREENSHOT - PREDICTION TAB



Demo: Asia năm 2002 → 67,0 năm

P(class ≥70)=79,6%

K-Means cluster 0.

Visualization tab - trực quan hóa AI

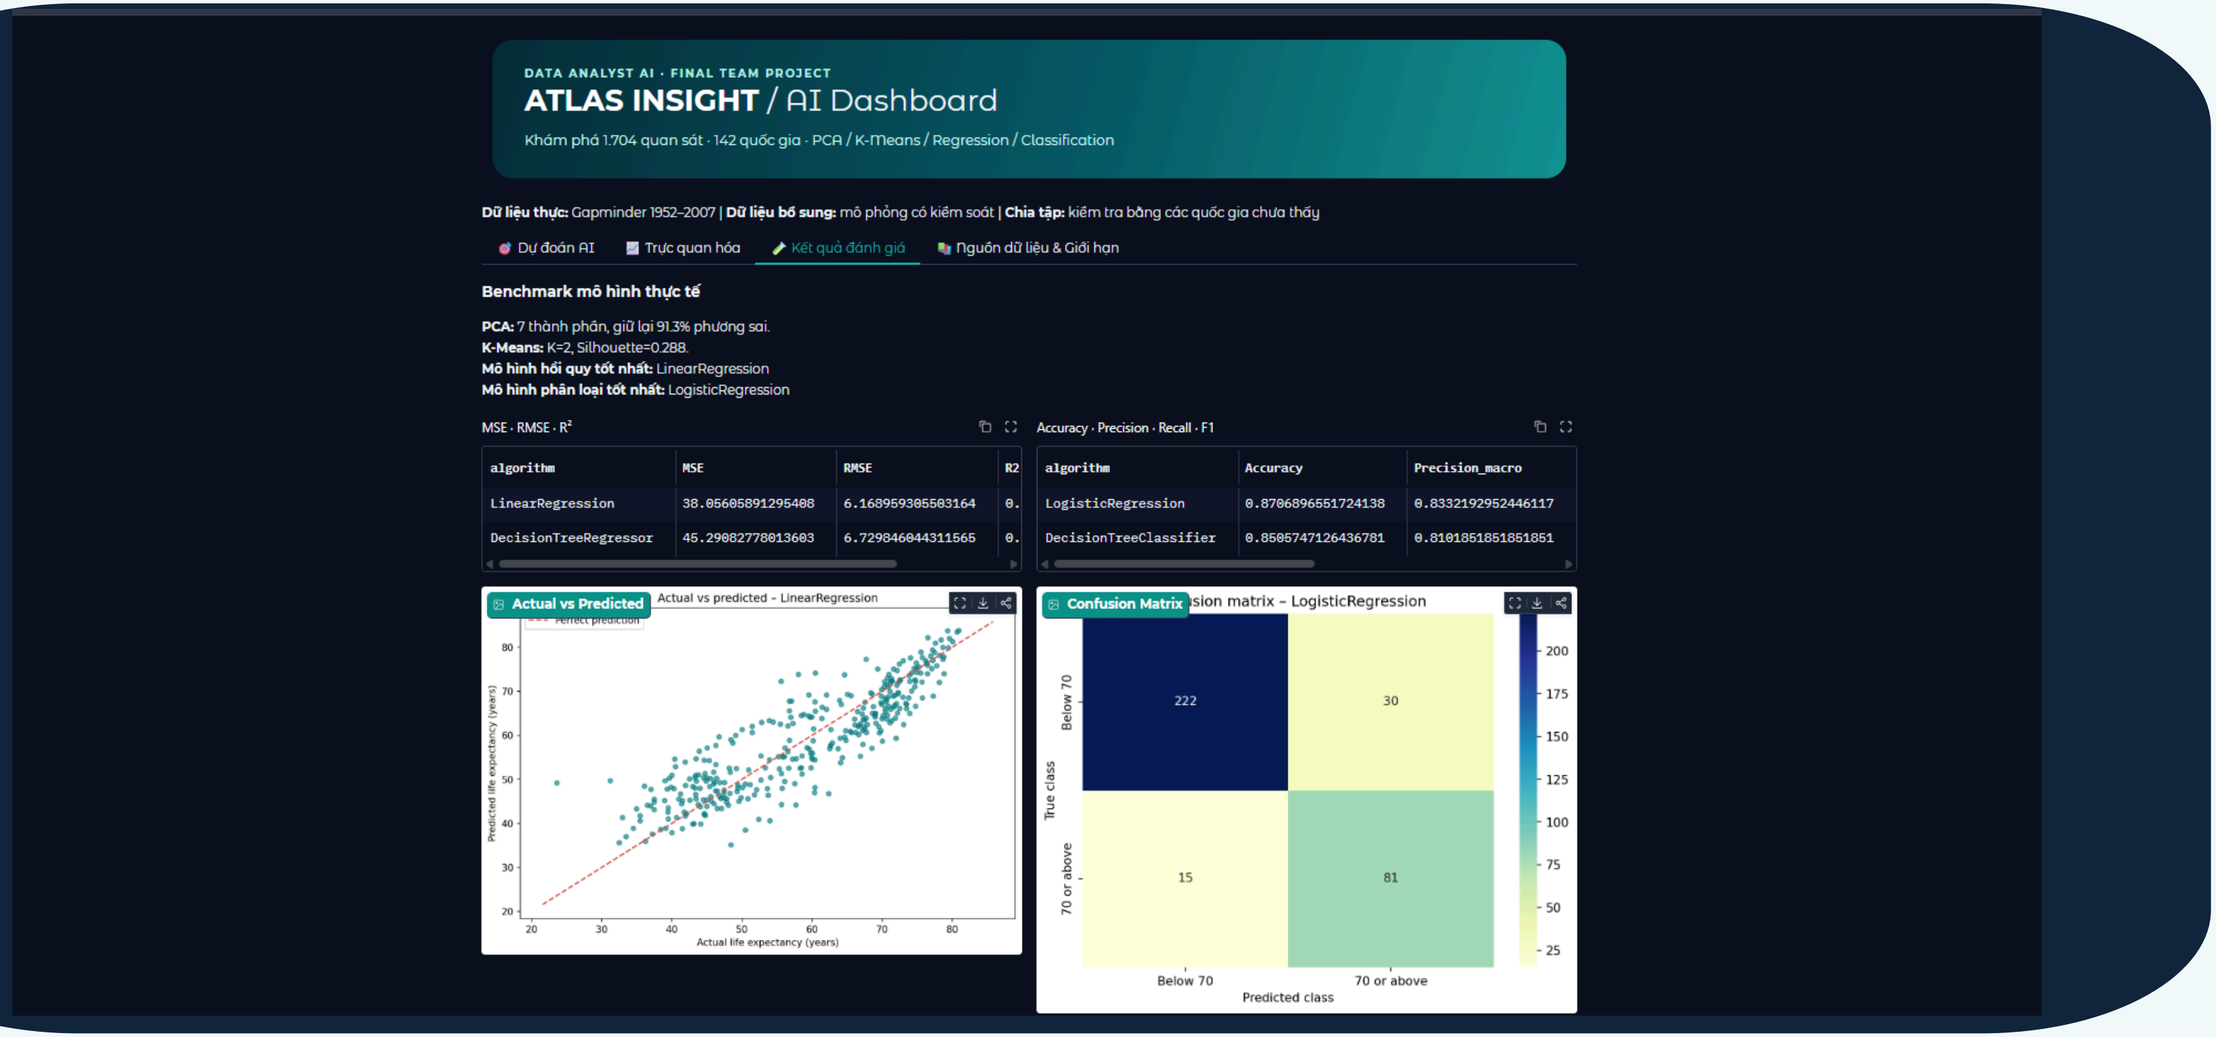
SCATTER / TREND / PCA / K-MEANS



Bằng chứng UI chạy thành công; biểu đồ Elbow/Silhouette đầy đủ trong charts và Notebook.

Evaluation + Data source tabs

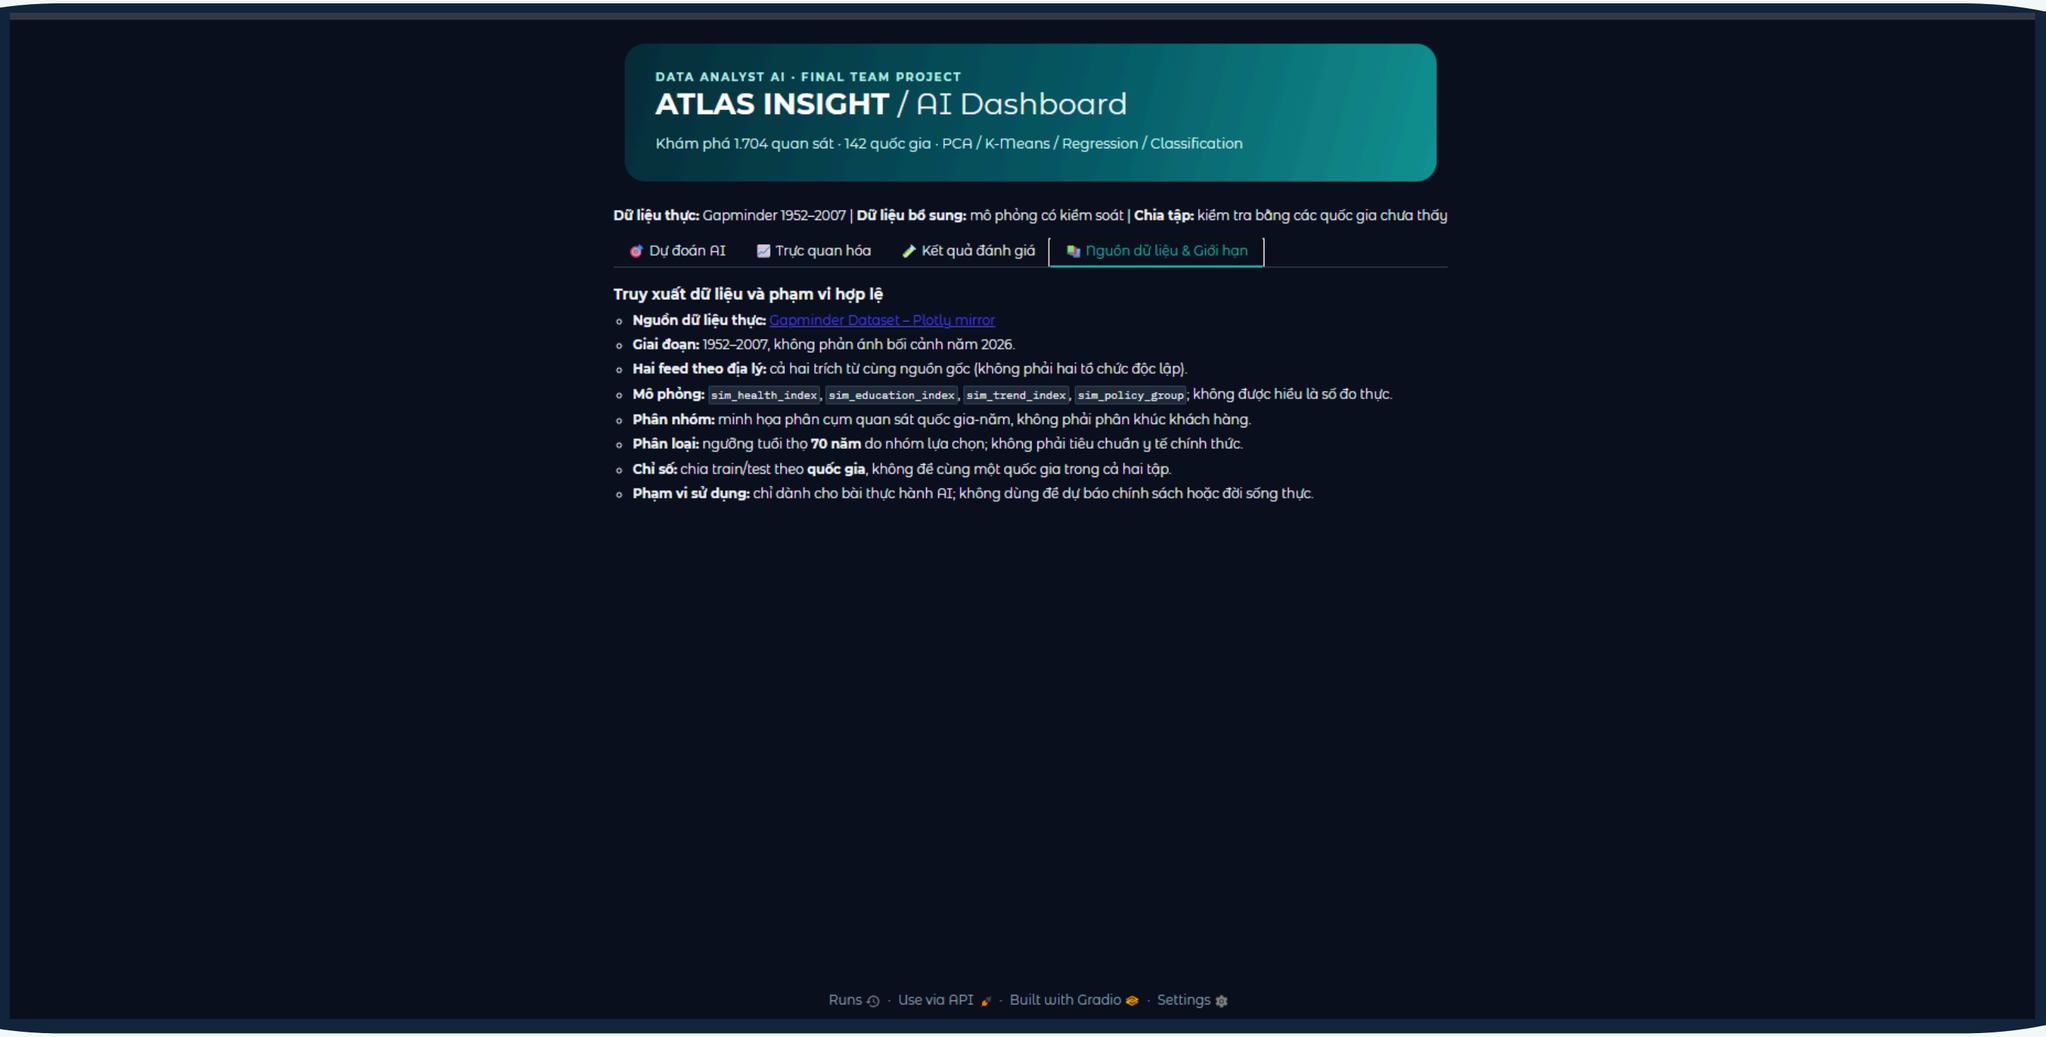
BENCHMARKS



Chụp màn hình từ môi trường Windows/Gradio của nhóm, không phải mockup thiết kế.

Evaluation + Data source tabs

SOURCE + LIMITATIONS



Chụp màn hình từ môi trường Windows/Gradio của nhóm, không phải mockup thiết kế.

THANK YOU / Q&A

ATLAS INSIGHT

Stage 1: nguồn - concat/merge - storage - EDA

Stage 2: PCA - K-Means - Regression - Classification - UI