FINAL GROUP PROJECT · STAGE 1 + STAGE 2

ATLAS INSIGHT

AI PHÂN TÍCH & DỰ ĐOÁN CHỈ SỐ PHÁT TRIỂN QUỐC GIA

Data Analyst AI • [Tên nhóm / MSSV] • 12.10.2026

Rubric đã triển khai

Bám sát 3 tài liệu yêu cầu được giao

GĐ1 – Data	1.704 dòng THỰC; concat 2 feed địa lý; merge dữ liệu giả lập
GĐ1 – Storage	SQLite đã hoạt động; ChromaDB có script, cần chạy tại máy nhóm
GĐ1 – EDA	375 thiếu mô phỏng → 0; 10 biểu đồ + phân tích So What
GĐ2 – ML	PCA + K-Means; 2 hồi quy; 2 phân loại; 16 đồ thị tổng
GĐ2 – UI	Gradio web app; cần chụp giao diện browser khi nộp

Bài toán & dữ liệu

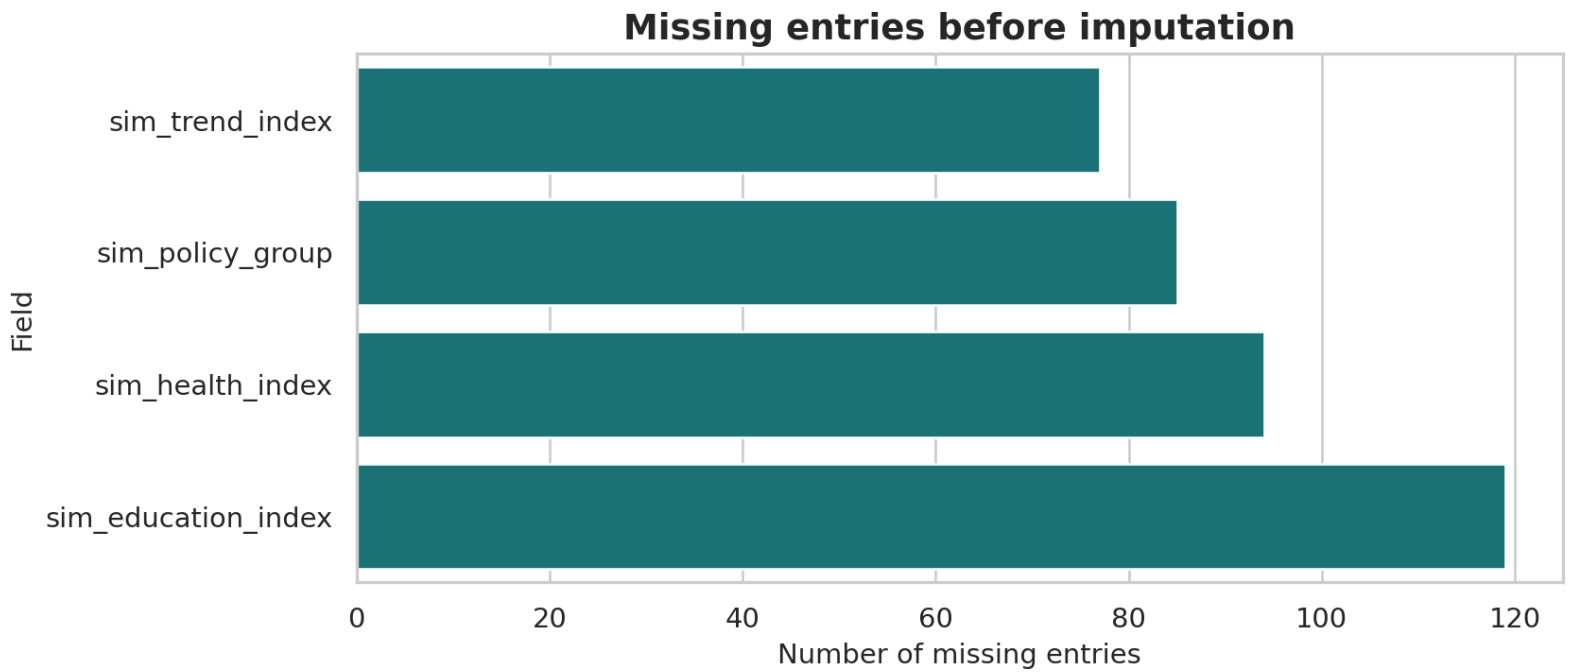
Regression	Dự đoán life_expectancy (năm) theo hồ sơ quốc gia-năm
Classification	Nhãn ≥70 năm: target_high_life_expectancy (0/1)
Segmentation	K-Means nhóm quan sát quốc gia-năm (không phải khách hàng)
Nguồn Gapminder	142 quốc gia × 12 mốc 1952–2007 = 1.704 quan sát
Hạn chế nguồn	Hai feed địa lý từ một bộ dữ liệu, chưa phải 2 nhà phát hành

Kiến trúc end-to-end

Static feeds	Gapminder → Africa/Asia (1.020) + các vùng còn lại (684)
Dynamic	Sinh sim_health / sim_education / sim_trend / policy, seed cố định
Integration	Align columns → pd.concat → record_id → left pd.merge
Storage + EDA	SQLite round trip → imputation → charts/insights
ML + Web UI	StandardScaler/OneHot → PCA/KMeans + Supervised → Gradio

Chất lượng dữ liệu

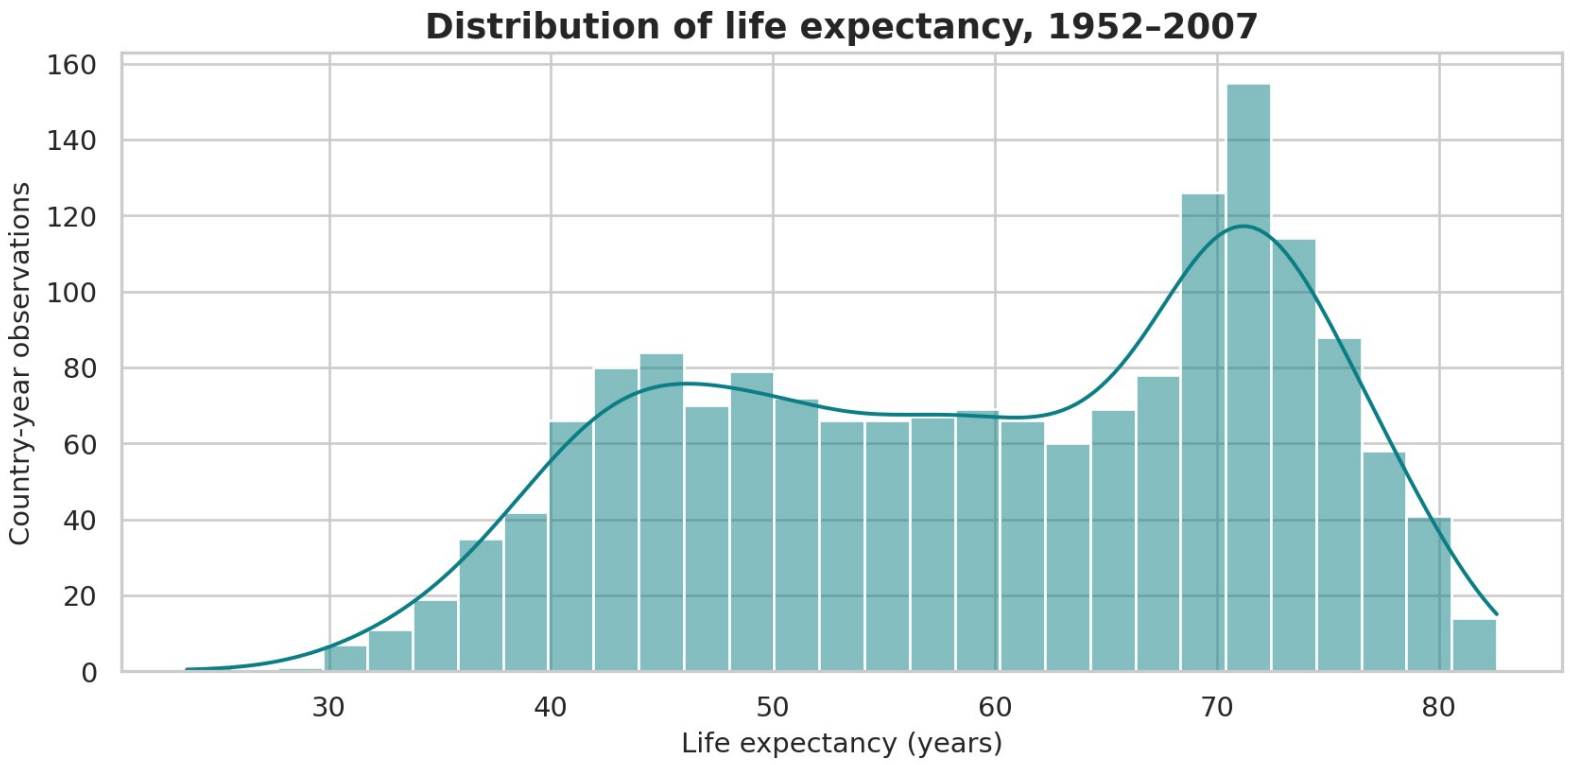
Data cleaning & validation



SO WHAT?

375 giá trị thiếu chỉ nằm ở các trường mô phỏng. Dùng median theo châu lục, ffill/bfill theo country và “Unknown”; còn 0 thiếu.

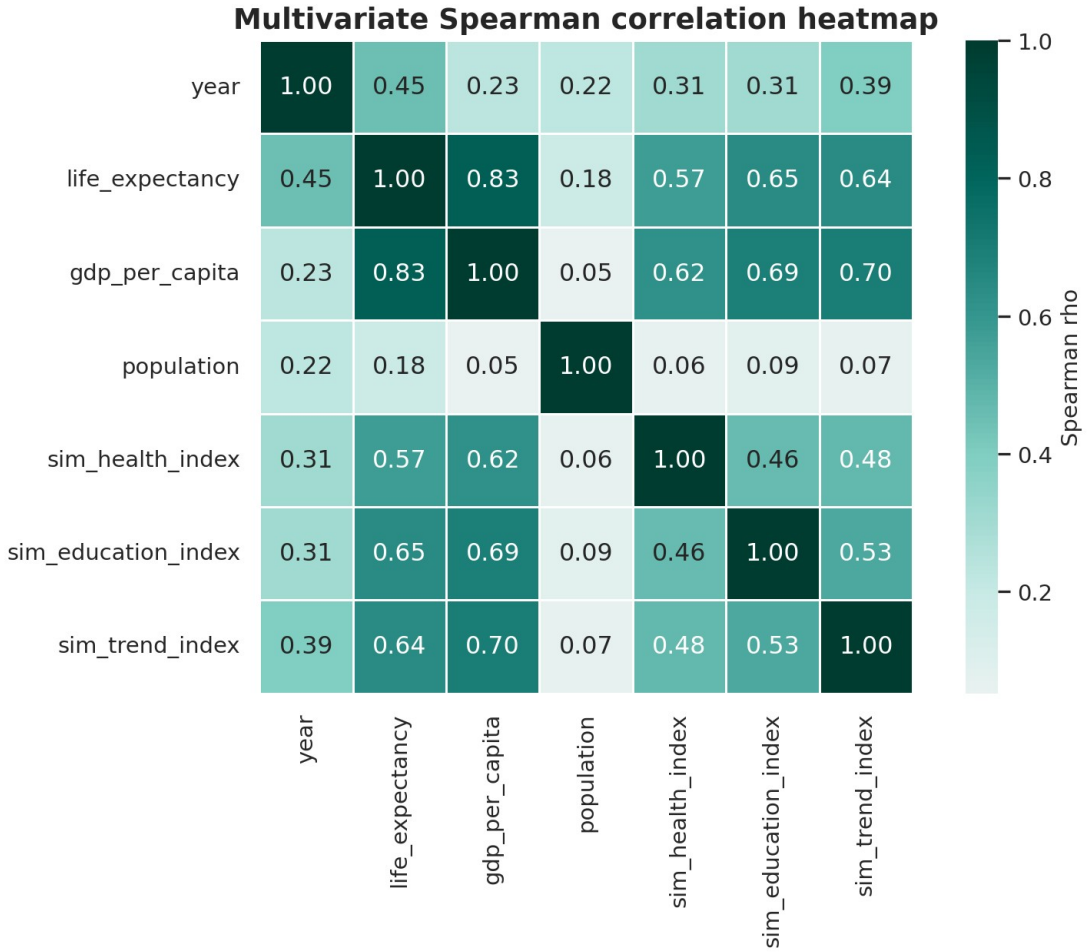
Tuổi thọ: phân bố thực



SO WHAT?

Tuổi thọ TB=59.47 năm. Phân phối đa dạng theo thời gian và châu lục → cần year và continent khi huấn luyện.

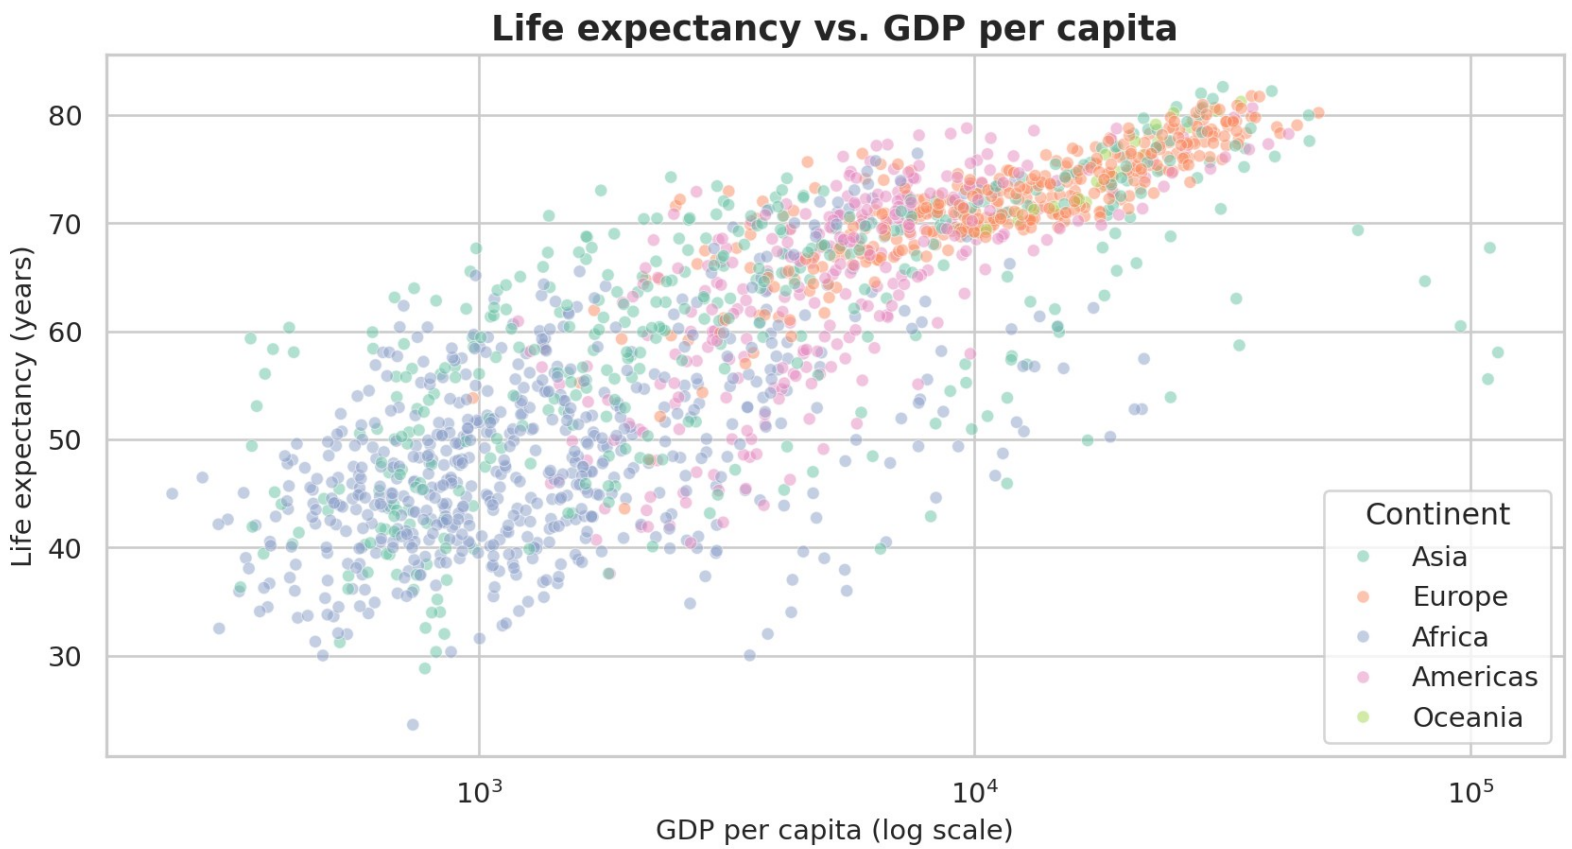
Tương quan các biến



SO WHAT?

Spearman GDP/người – tuổi thọ = 0.827. Quan hệ có ý nghĩa mô tả, KHÔNG chứng minh nhân quả.

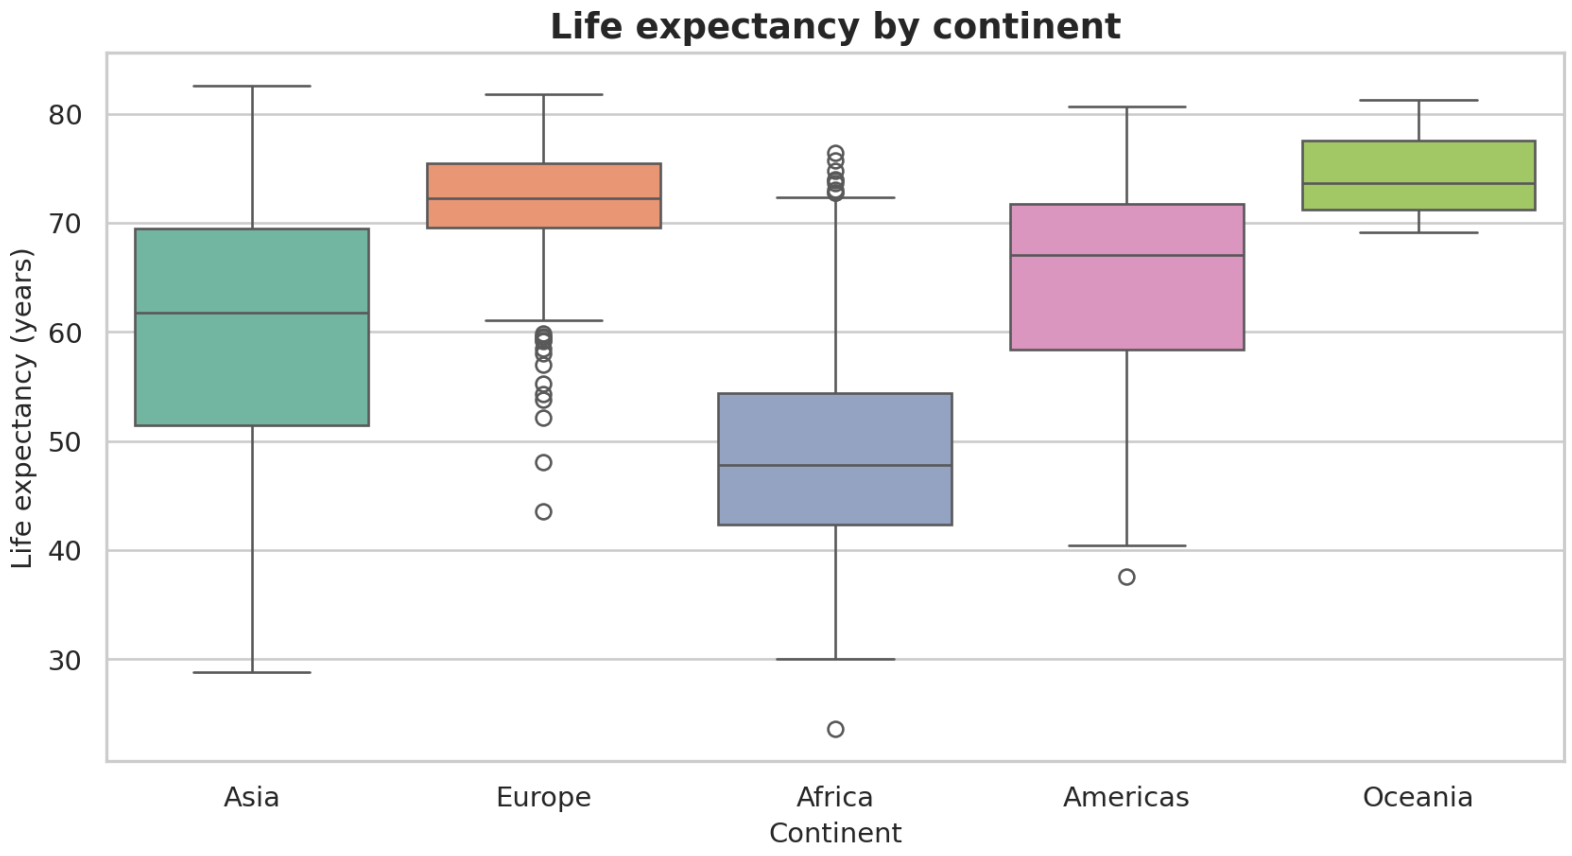
Tuổi thọ & GDP/người



SO WHAT?

Có xu hướng đồng biến không tuyến tính; dùng log1p(GDP) và so sánh tuyến tính với cây quyết định.

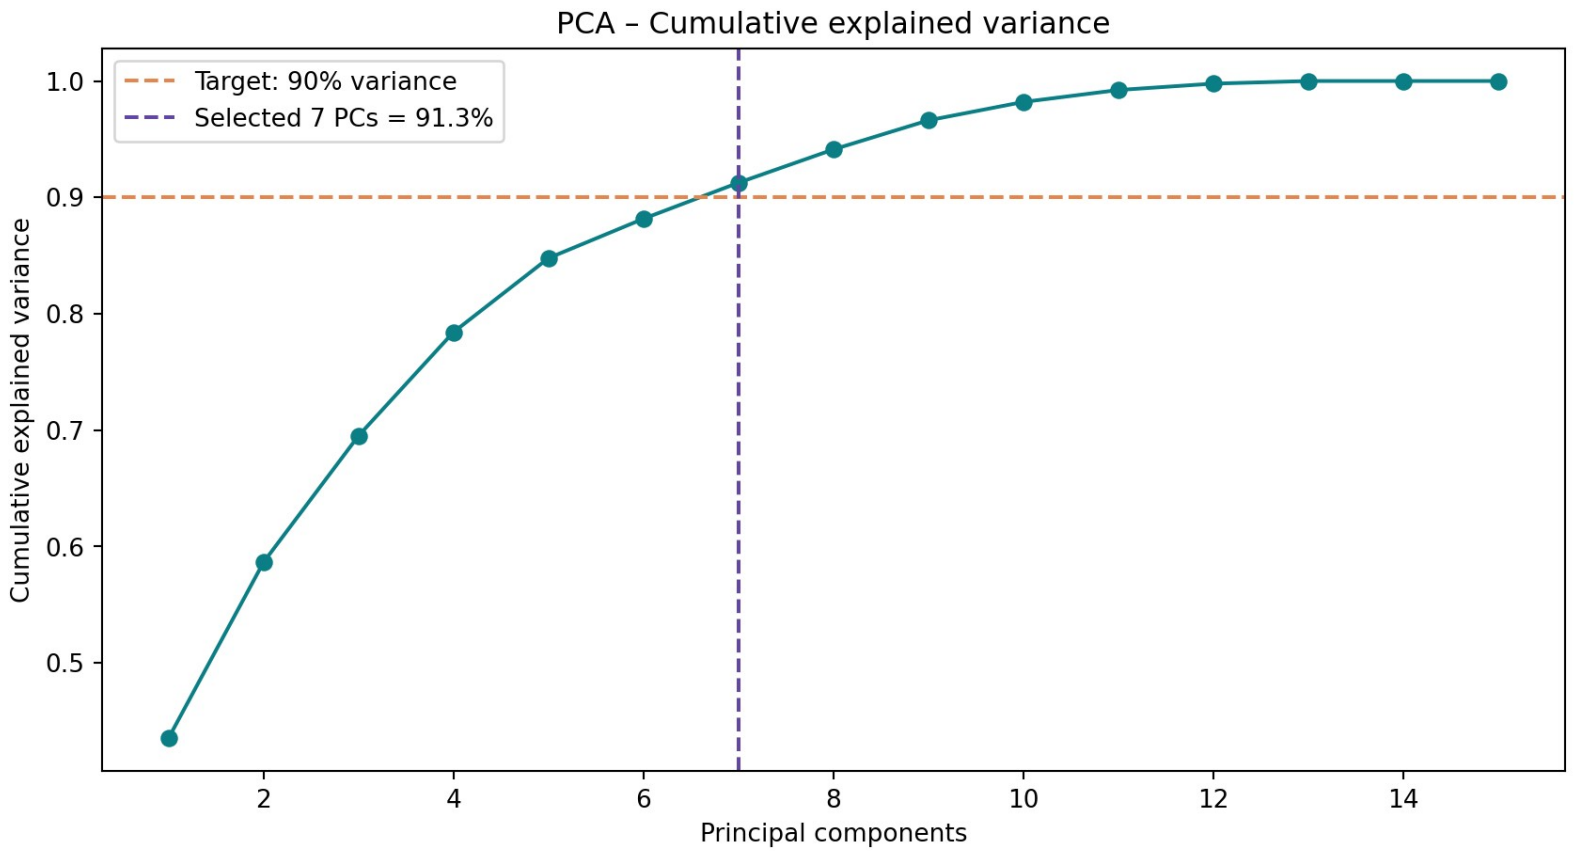
Khác biệt giữa châu lục



SO WHAT?

Africa ≈48,86 năm; Europe ≈71,90 năm. Oceania chỉ 24 quan sát → cẩn trọng với cỡ mẫu nhỏ.

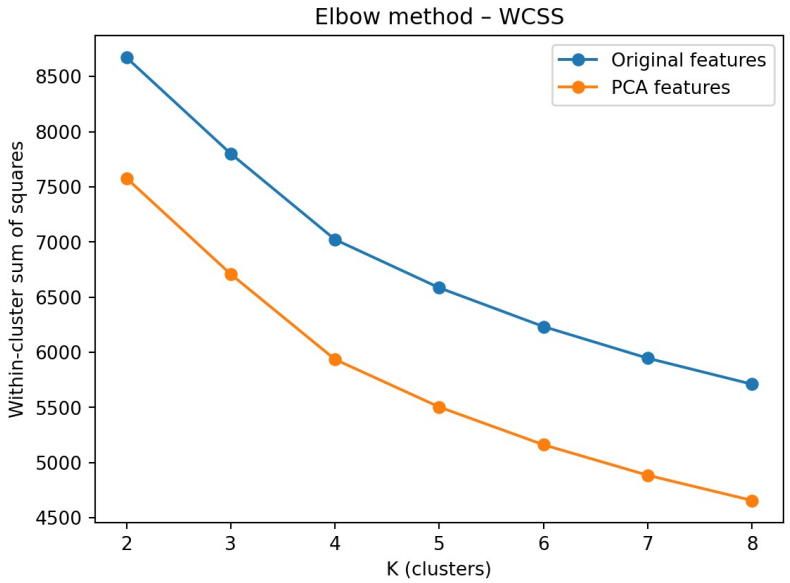
PCA: giữ phương sai



SO WHAT?

7 PCs giữ 91.26% phương sai; mục tiêu 90% nằm trong ngưỡng 85–95%.

Chọn K và so sánh không gian

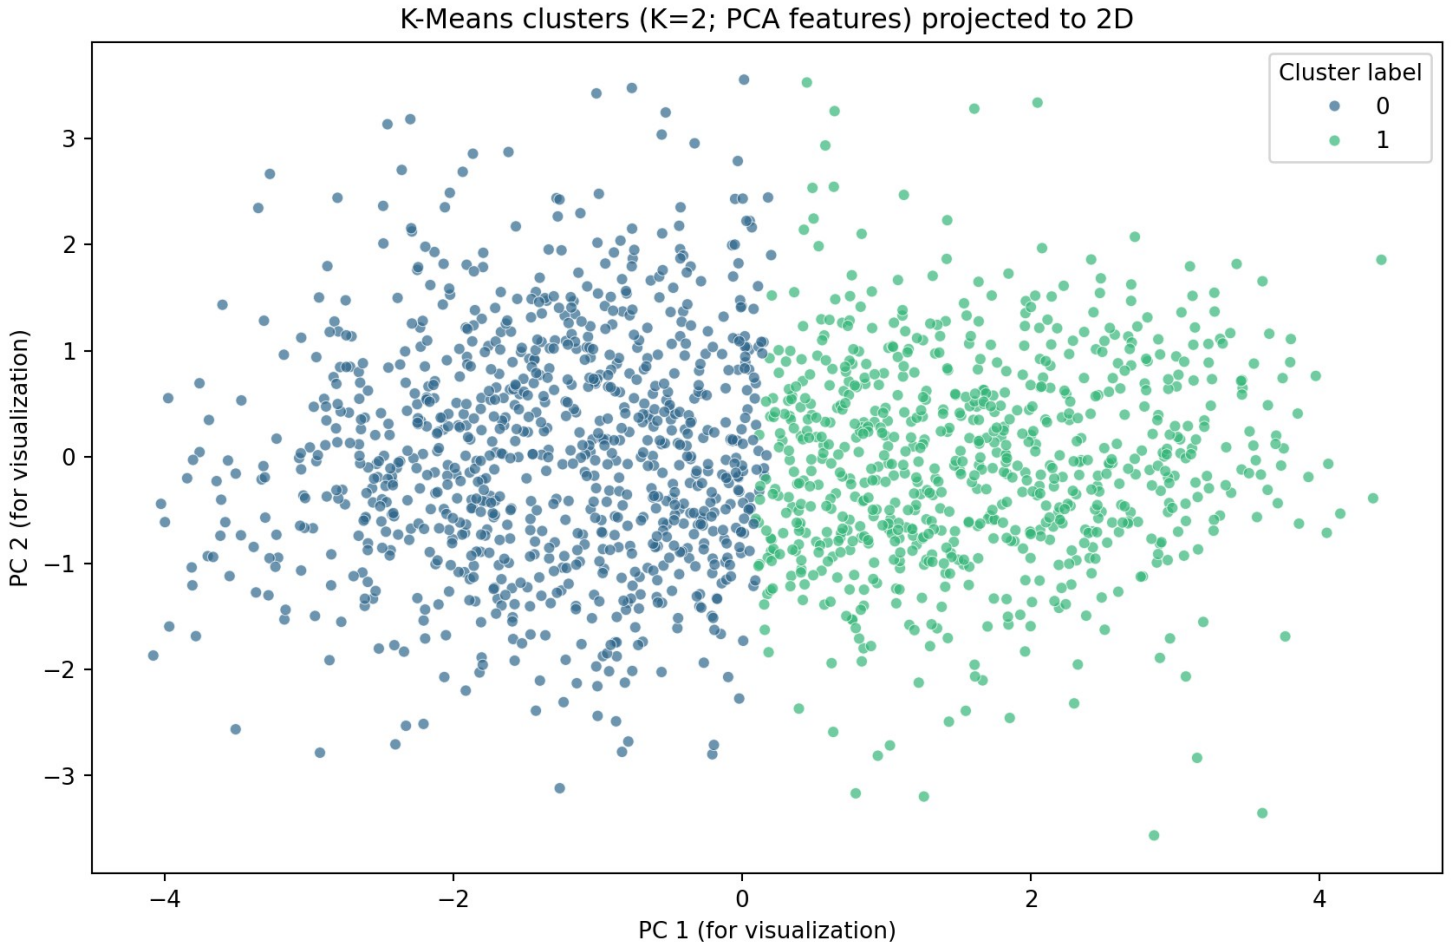




SO WHAT?

K=2; PCA silhouette=0.288, không PCA=0.264. Phân cụm ở mức vừa.

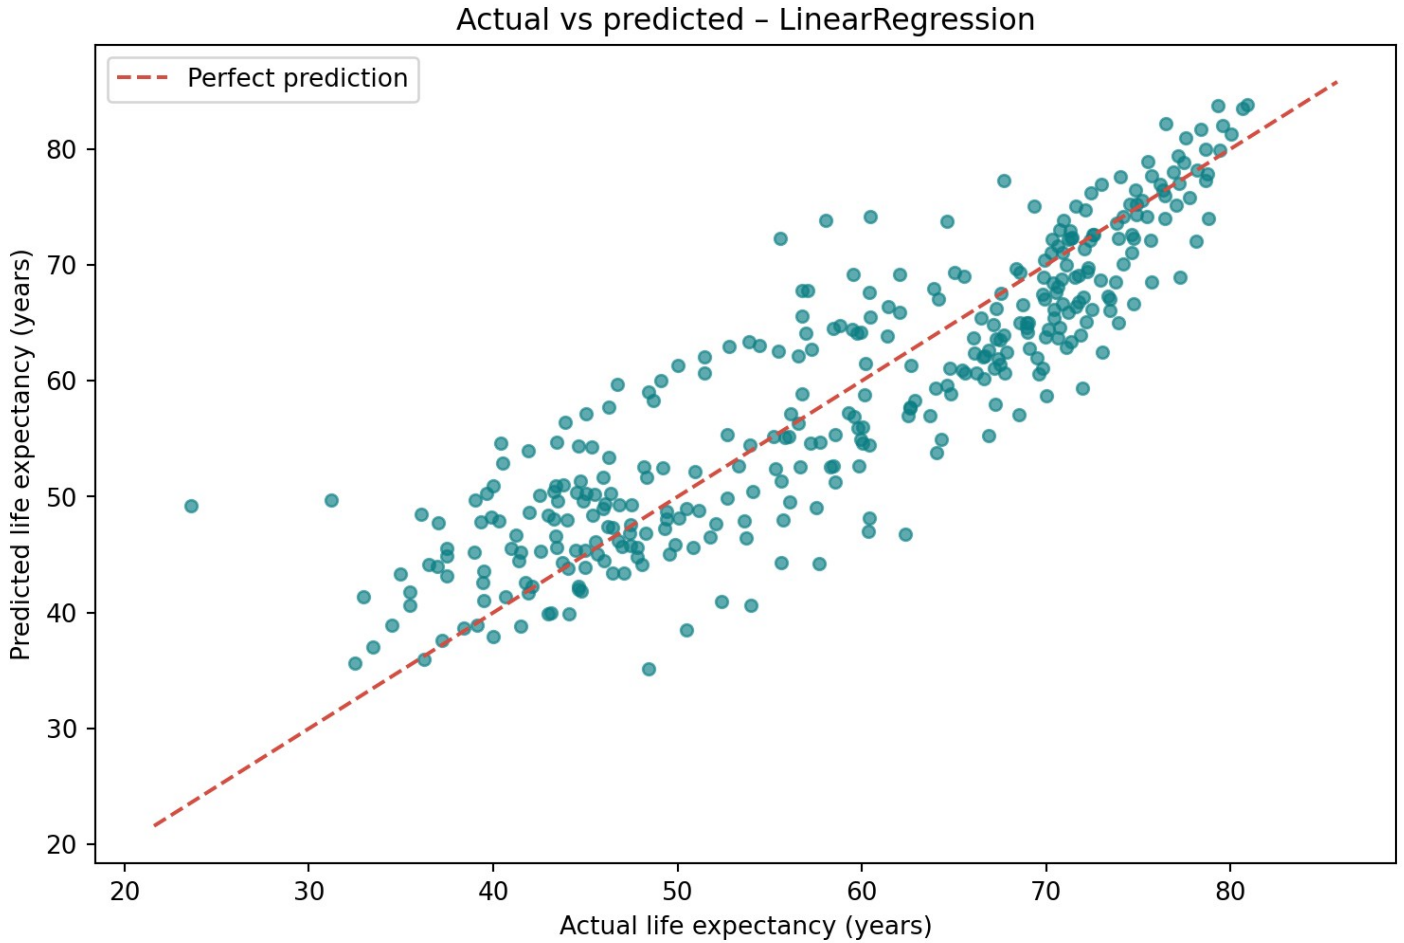
Phân cụm K-Means



SO WHAT?

Cụm 0: 931 quan sát, tuổi thọ TB 50,86. Cụm 1: 773 quan sát, tuổi thọ TB 69,85. Nhãn cụm được merge ngược dataset.

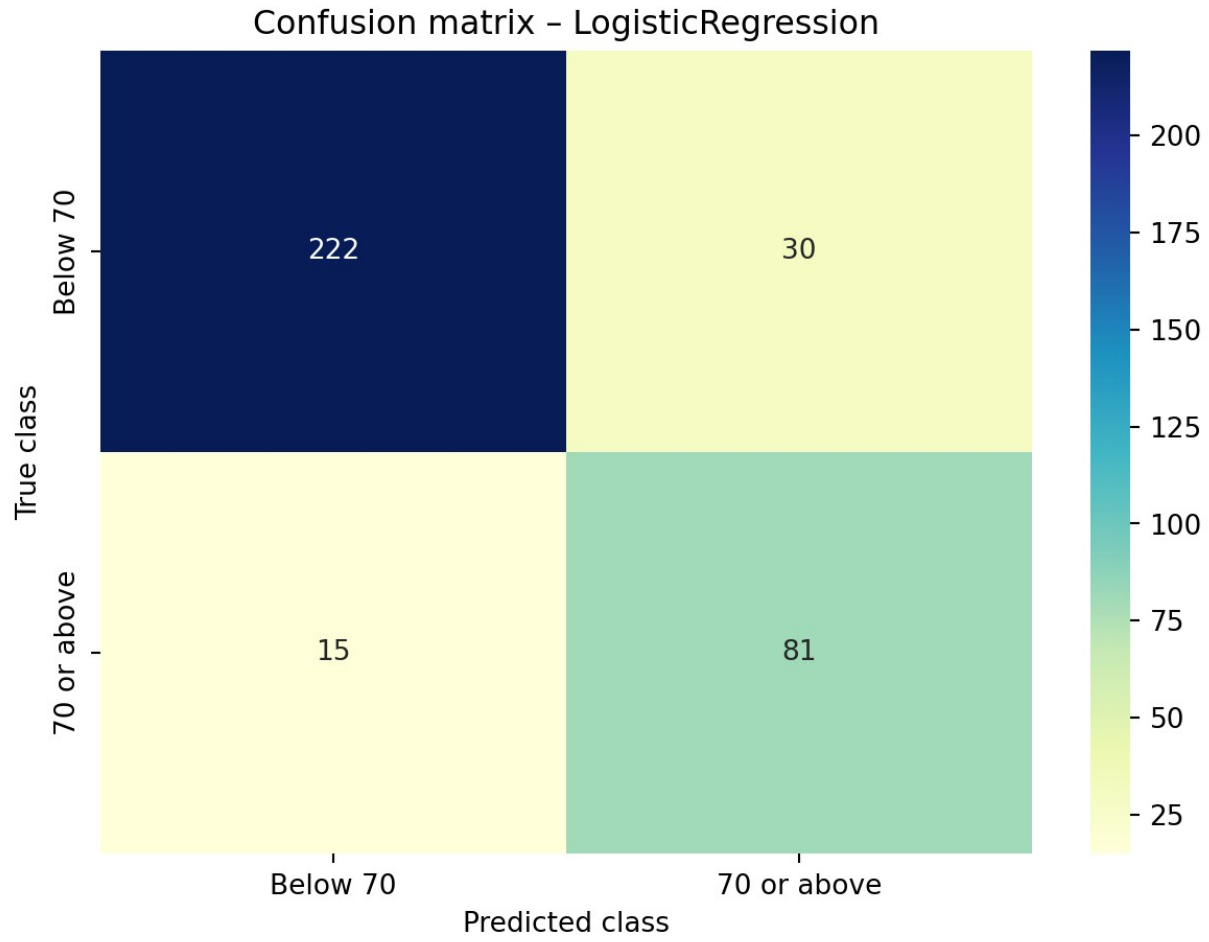
Regression: Actual vs Predicted



SO WHAT?

LinearRegression thắng: RMSE=6.17 năm, R^2=0.778; tree RMSE=6.73.

Classification: Confusion Matrix



SO WHAT?

LogisticRegression thắng: F1 macro=0.845, Accuracy=0.871. 222 TN · 30 FP · 15 FN · 81 TP.

Web UI — Gradio

Inputs	continent; year; population; GDP/người; 4 biến sim_*
Dự đoán	Tuổi thọ (hồi quy), xác suất và nhãn (phân loại), Cluster_Label
Trực quan	Scatter GDP/tuổi thọ, trend, PCA/K-Means charts
Benchmark	RMSE/MSE/R^2; F1/Precision/Recall; confusion matrix
Minh chứng	Code và HTTP 200 đã kiểm tra; screenshot browser cần chụp tại máy nhóm

3 khuyến nghị dựa trên dữ liệu

Ưu tiên kiểm định dữ liệu

Cụm GDP thấp có tuổi thọ lịch sử thấp hơn; tìm nguồn độc lập trước quyết định thực tế

Giữ baseline tuyến tính

RMSE 6,17 < 6,73; đánh giá sai số theo vùng, thời gian và bổ sung biến THỰC

Trình bày xác suất

F1 macro 0,845; lớp mất cân bằng nên tránh chỉ báo cáo Accuracy

Giới hạn & công việc cần hoàn tất

Nguồn	Hai feed không độc lập nhà phát hành; bổ sung nguồn thứ 2 nếu giảng viên yêu cầu chặt
Vector DB	Chạy ChromaDB trên máy có thể cài dependencies; kiểm chứng số bản ghi 1.704
Screenshots	Chạy Gradio trên trình duyệt máy nhóm; chụp ảnh màn hình thật và chèn báo cáo
Extra credit	Web crawl/LLM code được cung cấp nhưng chưa chạy vì hạn chế mạng/mô hình
Giới hạn khoa học	Dữ liệu 1952–2007; sim_* giả lập; không dùng làm dự báo năm 2026

CẢM ƠN THẦY/CÔ

Q&A · Data Analyst AI · ATLAS INSIGHT

Liên kết code, báo cáo, chart và bộ dữ liệu: xem thư mục ZIP nộp nhóm